

Rapport de TER : Détection et classification automatique des défauts dans une image thermique en se basant sur les méthodes d'apprentissage profond

Matéo MUNOZ

Février 2024

Résumé

Le projet d'ouverture à la recherche, intitulé "Détection et classification automatique des défauts dans une image thermique en se basant sur les méthodes d'apprentissage profond", vise à développer un système avancé de diagnostic des défauts sur des soudures, en utilisant des modèles d'apprentissage profond. L'objectif principal est de mettre en place un système robuste et performant, capable de détecter automatiquement les anomalies dans les images thermiques de soudures, tout en les classifiant avec précision. Ce projet implique l'utilisation de Python pour l'apprentissage profond et Qt avec PyQt pour développer une interface utilisateur conviviale. Les défis comprennent la disponibilité limitée et la qualité des données d'entraînement, ainsi que la nécessité de maintenir des performances élevées malgré les variations dans les conditions de détection.

Mots-clés : Détection automatique de défauts, Images thermiques, Apprentissage profond

1 Introduction

La détection automatique et la classification des défauts dans les images thermiques revêtent une importance cruciale dans de nombreux domaines, notamment l'industrie, où la fiabilité des soudures et des assemblages est essentielle. Ce rapport présente les résultats et les conclusions d'un projet de recherche axé sur le développement d'un système pour cette tâche spécifique. En combinant les avancées en vision par ordinateur et en apprentissage profond, notre projet vise à automatiser ce processus critique, offrant ainsi une solution efficace et précise pour l'inspection des soudures. À travers ce rapport, nous explorerons les différentes étapes du projet, de la recherche et de la sélection des méthodes appropriées à la mise en œuvre et à l'évaluation du système proposé. Nous discuterons également des défis rencontrés, des solutions développées et des perspectives futures pour cette technologie.

2 Contexte du projet

2.1 Contexte du Projet de Détection de Défauts dans les Images Thermiques

Le projet de détection automatique et de classification des défauts dans les images thermiques constitue une réponse aux besoins croissants de l'industrie en matière d'inspection et de contrôle qualité. Dans un environnement où la fiabilité des soudures et des assemblages est primordiale, la capacité à détecter et classifier rapidement les défauts revêt une importance capitale pour garantir la sécurité et la qualité des produits fabriqués.

Ce projet vise à développer un système capable d'analyser automatiquement les images thermiques de soudures, afin d'identifier tout défaut potentiellement présent. En utilisant des modèles d'apprentissage profond, notre objectif est de proposer une solution efficace et précise pour l'inspection des soudures, offrant ainsi un outil fiable et performant pour détecter les anomalies.

Les défauts à détecter ont été définis de façon préliminaire dans ce projet, le projet se concentre donc sur la mise en exploitation des données pour l'apprentissage et sur l'apprentissage en lui-même.




FIGURE 1 – Échantillons des défauts à détecter avec le modèle final

2.2 Méthodologie et Outils Utilisés

Pour atteindre nos objectifs, nous avons sélectionné avec soin les outils les plus adaptés à notre projet. Nous utilisons principalement Python pour le développement de notre système de détection de défauts. La richesse de ses bibliothèques d'apprentissage profond, sa flexibilité et sa facilité d'utilisation en font un choix idéal pour notre application.

Nous utilisons également PyQt, une bibliothèque Python, pour créer une interface utilisateur conviviale, permettant une interaction intuitive avec notre système de détection de défauts. Cette interface facilite la visualisation des images thermiques, des défauts détectés et de leurs classifications, contribuant ainsi à une utilisation efficace du système dans des environnements industriels.

Nous avons utilisé l'API Darknet[Wang et al.(2021)Wang, Bochkovskiy, and Liao] de Alexey Bochkovskiy. Bien que son utilisation principale ait été pour l'entraînement du modèle et la génération des graphes d'évaluation, cette plateforme d'apprentissage profond nous a permis de travailler avec des modèles pré-entraînés, ce qui a accéléré le processus de développement tout en garantissant des résultats précis et fiables pour la détection de défauts dans les images thermiques de soudures.

Pour pouvoir entraîner le modèle convenablement, il était nécessaire de labelliser les données. Pour ce faire, nous avons utilisé l'application Labellmg. Labellmg est un outil d'annotation d'images largement utilisé pour marquer et étiqueter des objets dans des images. Dans ce projet, il a été précieux pour son interface conviviale facilitant l'annotation rapide et précise des images thermiques. Il supporte plusieurs formats d'images, garantit la sauvegarde automatique des annotations, et est open-source, offrant ainsi une solution flexible et économique pour l'annotation d'images.

2.3 Objectifs et Contributions du Projet

Le projet de détection automatique et de classification des défauts dans les images thermiques s'inscrit dans une démarche globale visant à améliorer les processus d'inspection et de contrôle qualité dans divers secteurs industriels. Ses objectifs sont multiples et ses contributions potentielles sont significatives.

Tout d'abord, l'objectif primaire est de développer un système capable de détecter automatiquement les défauts présents dans les images thermiques de soudures. Cela implique la mise en place d'algorithmes de traitement d'image avancés, qui peuvent identifier avec précision les anomalies, même dans des conditions variables telles que des changements de luminosité ou des angles de vue différents. La fiabilité de cette détection est cruciale pour garantir la sécurité des structures soudées et des produits finaux.

Ensuite, le projet vise également à classifier les défauts détectés. Il ne suffit pas seulement de repérer les anomalies ; il est également essentiel de les catégoriser pour permettre une action corrective appropriée. Par exemple, faire la différence entre différents types de fissures ou de porosités peut orienter les décisions de

maintenance ou de réparation, contribuant ainsi à prolonger la durée de vie des équipements et à minimiser les risques de défaillance.

Une autre contribution majeure de ce projet réside dans le développement d'une interface utilisateur conviviale. Si les algorithmes de détection et de classification constituent le cœur du système, leur utilité pratique dépend également de la facilité avec laquelle les utilisateurs peuvent interagir avec l'outil. En concevant une interface intuitive et ergonomique, nous visons à rendre notre solution accessible à un large éventail d'utilisateurs, y compris ceux qui n'ont pas nécessairement une expertise technique approfondie en matière de vision par ordinateur ou d'apprentissage profond.

3 Travail de recherche

L'évolution rapide de l'intelligence artificielle, notamment des méthodes d'apprentissage profond, a révolutionné la manière dont nous abordons les problèmes complexes, notamment dans le domaine de l'analyse d'images thermiques. Ce domaine est crucial dans divers secteurs tels que le contrôle non-destructif des matériaux, la surveillance industrielle et l'inspection électrique. Dans ce contexte, nous avons réalisé un état de l'art se penchant sur l'application des modèles d'apprentissage profond pour la détection et la classification automatiques des défauts dans les images thermiques. Cette partie est un résumé détaillé de l'état de l'art complet, qui est disponible en annexe.

3.1 Compte rendu de l'état de l'art

Trois articles de recherche récents ont été sélectionnés et minutieusement étudiés pour explorer les différentes approches et méthodologies utilisées dans le domaine de la détection et de la classification automatiques des défauts dans les images thermiques.

3.1.1 Thermographie optique pulsée dans le contrôle non-destructif des composites

Le premier article se concentre sur l'application de la thermographie optique pulsée dans le contrôle non destructif des composites[Luo et al.(2019)Luo, Gao, Woo, and Yang]. Il met en avant l'utilisation de réseaux de neurones à convolution (CNN) pour la segmentation des défauts. Les méthodes d'extraction de caractéristiques telles que l'analyse en composantes principales (PCA) et la reconstruction du signal thermographique (TSR) sont également explorées. L'approche de "cross learning" est introduite pour améliorer la détection des défauts. Les résultats montrent que l'approche VGG-Unet offre de meilleures performances en combinant les avantages de la segmentation de petits ensembles d'échantillons avec les poids pré-entraînés de VGG.

3.1.2 Utilisation de Hybrid-YOLO pour la classification des défauts d'isolateurs dans les lignes de transmission

Le deuxième article présente l'utilisation d'une version hybride du modèle YOLO pour la classification des défauts d'isolateurs dans les lignes de transmission[Souza et al.(2023)Souza, Stefenon, Singh, and Freire]. Il souligne la rapidité et la précision de ce modèle, surpassant plusieurs versions de YOLO ainsi que d'autres architectures établies telles que VGG-11 et ResNet-34. Notamment, Hybrid-YOLO démontre une capacité exceptionnelle à fournir des résultats avec un petit ensemble de données, ce qui est crucial dans des applications où les données sont souvent limitées.

3.1.3 Apprentissage profond pour la détection de problèmes de qualité dans la production de sacs en papier

Le troisième article explore l'utilisation de Faster R-CNN pour la détection de problèmes de qualité dans la production de sacs en papier[Syberfeldt and Vuoluterä(2020)]. Il met en avant l'efficacité de ce modèle par rapport à l'inspection manuelle, obtenant une précision de 94,5%. Cependant, des préoccupations subsistent quant à sa robustesse dans des conditions environnementales variables, nécessitant une évaluation plus approfondie.

3.1.4 Analyse comparative des différents modèles

L'analyse comparative des différents modèles révèle plusieurs aspects importants. En termes de précision de la détection des défauts, Hybrid-YOLO surpasse les autres modèles, tandis que VGG-Unet avec la stratégie de "cross learning" offre de bonnes performances et une facilité de prise en main. Pour la capacité à traiter des ensembles de données limités, Hybrid-YOLO et Faster R-CNN se démarquent. En revanche, pour la généralisation sur des ensembles de données variés, Hybrid-YOLO et VGG-Unet semblent plus robustes. Enfin, en termes d'efficacité dans des conditions environnementales variables, VGG-Unet avec la stratégie de "cross learning" semble être le plus adapté.

Le choix d'opter pour le modèle YOLO est motivé par sa simplicité, sa rapidité, sa robustesse et la disponibilité de ressources pour son apprentissage. Malgré les améliorations spécifiques offertes par Hybrid-YOLO, le choix de YOLO est justifié par sa performance globale et sa facilité d'utilisation, notamment dans des scénarios de production où la rapidité et la fiabilité sont essentielles.

4 Travail réalisé

Pour aboutir au rendu final fonctionnel, plusieurs étapes ont été nécessaires, chacune visant à résoudre des problèmes spécifiques rencontrés lors du développement. Voici une vue d'ensemble des principales étapes de mise en œuvre du projet, axées sur la résolution des défis rencontrés :

4.1 Compréhension et mise en place du modèle YOLO avec OpenCV

Pour intégrer le modèle YOLO dans le projet, la bibliothèque OpenCV a été utilisée, notamment son module DNN (Deep Neural Networks). Ce module permet de charger des modèles de réseaux neuronaux profonds pré-entraînés, tels que YOLO, pour la détection d'objets dans des images.

L'étape initiale consistait à charger les poids pré-entraînés du modèle YOLO à l'aide du module DNN d'OpenCV. Ensuite, le processus de détection d'objets a été configuré pour traiter les images thermiques en utilisant ce modèle. La flexibilité et la facilité d'utilisation de l'API DNN d'OpenCV ont grandement simplifié cette intégration, permettant ainsi une mise en œuvre efficace du modèle YOLO pour la détection des défauts dans les images thermiques.

Enfin, le processus de détection d'objets a été mis en place. Cela implique de fournir une image en entrée au modèle, puis de passer cette image à travers le réseau pour obtenir les prédictions de détection d'objets. Ces prédictions comprennent les emplacements des objets détectés ainsi que les étiquettes correspondantes et les scores de confiance associés à chaque détection.

4.2 Prétraitement des données

L'un des défis prépondérants était la qualité et l'accessibilité des données. Avant de pouvoir initier l'entraînement du modèle, il a fallu procéder au nettoyage et à l'annotation d'un ensemble de données représentatif. Ce processus s'est articulé autour de deux principales étapes : l'augmentation des données et la labellisation des données.

Pour l'augmentation des données, les techniques employées afin d'accroître la diversité et la quantité des exemples disponibles pour l'entraînement est la rotation des images du set de base. Cette augmentation de données a permis d'améliorer la capacité du modèle à généraliser et à reconnaître les défauts dans des situations variées, mais aussi à éviter le sous-entraînement.

Les données ont été divisées en deux ensembles distincts : un ensemble d'entraînement et un ensemble de test. Cette division est cruciale pour évaluer l'efficacité du modèle. L'ensemble d'entraînement a été utilisé pour ajuster les poids du modèle pendant l'apprentissage, tandis que l'ensemble de test a permis d'évaluer ses performances sur des données inconnues. Cela garantit une évaluation impartiale de sa capacité à généraliser.

et à détecter efficacement les défauts thermiques. Sur ce projet, le nombre d'images d'entraînement total était de 4230 images, dont 3575 étaient dédiées à l'entraînement du modèle et 655 étaient dédiées aux tests.

Quant à la labellisation des données, elle a constitué une étape cruciale pour fournir au modèle des informations précises sur la localisation et la nature des défauts thermiques dans les images. Chaque image a dû être examinée attentivement, et chaque défaut identifié a été annoté avec précision pour indiquer sa position et sa catégorie. Cette tâche a exigé une attention méticuleuse pour garantir que le modèle soit entraîné sur des données de haute qualité, minimisant ainsi les risques de biais et d'erreurs lors de la détection des défauts dans de nouvelles images thermiques.

4.3 Entraînement du modèle

L'entraînement du modèle YOLO a nécessité une infrastructure appropriée pour gérer un grand volume de données et itérer rapidement sur différents modèles. Pour ce faire, l'API Darknet a été utilisée, offrant une plateforme flexible et puissante pour le développement et l'entraînement de modèles de détection d'objets. Cette API a permis de régler les hyperparamètres du modèle, de gérer efficacement les ressources informatiques et de suivre les performances du modèle au fil du temps.

L'utilisation de l'API Darknet a simplifié le processus d'entraînement en offrant une interface intuitive pour charger les données, configurer le modèle et lancer l'entraînement. De plus, elle a fourni des outils intégrés pour surveiller les métriques de performance telles que la perte d'entraînement et l'exactitude de la détection. On peut voir sur la figure 2 le graphe d'entraînement, avec la perte en fonction du nombre d'itération et la valeur mAP@0.5 en fonction du nombre d'époques parcouru.




FIGURE 2 – Graphe d'entraînement du modèle final. (mAP@0.5)

L'indice mAP@0.5 (mean Average Precision at 0.5) est une mesure utilisée pour évaluer les performances des modèles de détection d'objets, comme YOLO ou Faster R-CNN. Il calcule la précision moyenne des détections sur toutes les classes à un seuil de chevauchement (IoU) de 0.5 entre les prédictions et les vérités terrain (i.e. le cadrage du défaut détecté par le modèle recouvre au moins à 50 pourcent le vrai label). Un mAP@0.5 élevé indique une meilleure capacité du modèle à détecter avec précision les objets dans les images. On atteint ici pour la meilleur version du modèle un mAP@0.5 de 76%, qui est satisfaisante pour l'application qui est faite ici (cette valeur est calculée sur le set de test, qui n'est pas utilisé pour entraîner le modèle).

L'exploitation de l'API Darknet a facilité et accéléré le processus d'entraînement du modèle YOLO en fournissant des outils puissants pour la gestion des données, la configuration du modèle et le suivi des performances, tout en exploitant efficacement les capacités de calcul des GPU.

4.4 Présentation des résultats et validation

Dans cette section, nous présentons les résultats obtenus après l'entraînement et la validation du modèle YOLO pour la détection des défauts thermiques.

4.4.1 Résultat

Tout d'abord, les performances du modèle ont été évaluées à l'aide de métriques telles que la précision moyenne par classe, la précision générale, le rappel et le F1-score.




FIGURE 3 – Précision moyenne par classe

Comme on peut le voir sur la figure 3, la précision moyenne pour la détection est généralement plus élevée sur le set d'entraînement que sur le set de test. Cependant, la précision sur le set de test reste satisfaisante, on remarque surtout que la précision pour la détection de la classe "Normal" (i.e. pas de défauts détectés) est très élevée et n'a qu'une faible différence avec la précision sur le set d'entraînement.

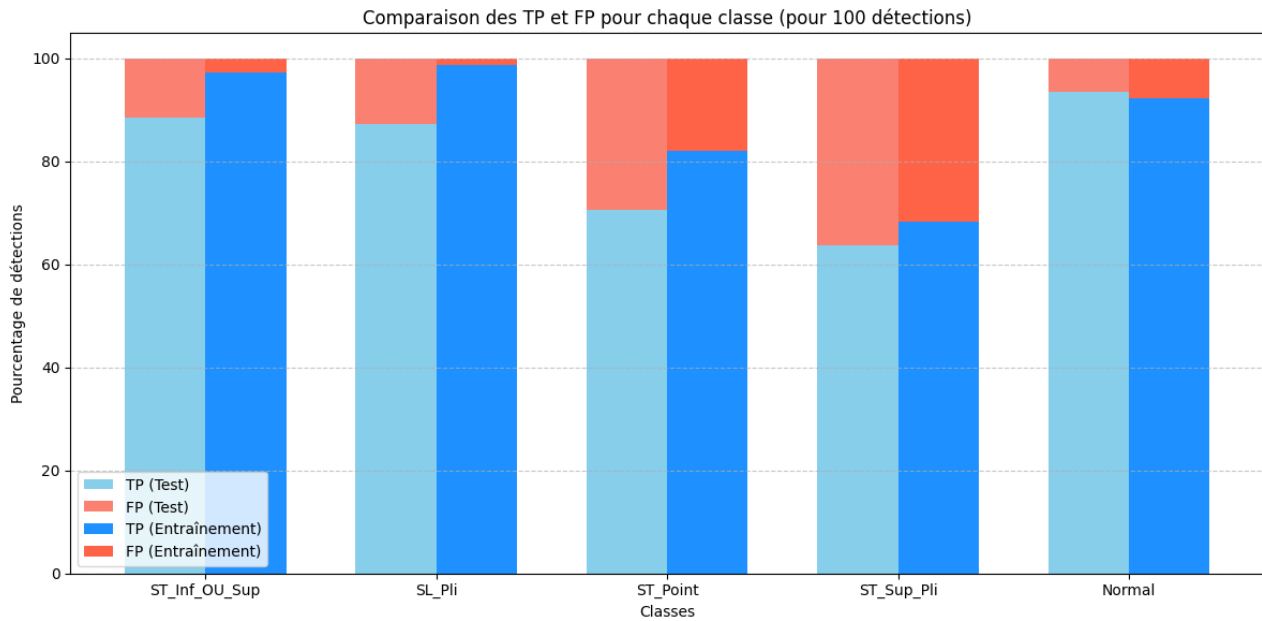


FIGURE 4 – Vrai et Faux positif par classe pour 100 détections

La figure 4 met en évidence les défauts que le modèle détecte le mieux, et ceux pour lequel il est moins bon. Comme dit précédemment la classe "Normal" obtient un rapport Vrai positif / Faux négatif très satisfaisant (supérieur ou égal à 90%, c'est à dire qu'on ne se trompe pas 90% du temps au moins), on peut dire la même chose pour les défauts ST_Inf_OU_Sup et SL_Pli. Pour ST_Point et ST_Sup_Pli, les résultats sont moins bon (compris entre 60 et 70% sur le set de test), une explication pourrait être que ces défauts sont plus fin à détecter et que le modèle aurait besoin de plus d'échantillons variés de ces défauts-là pour l'entraînement.

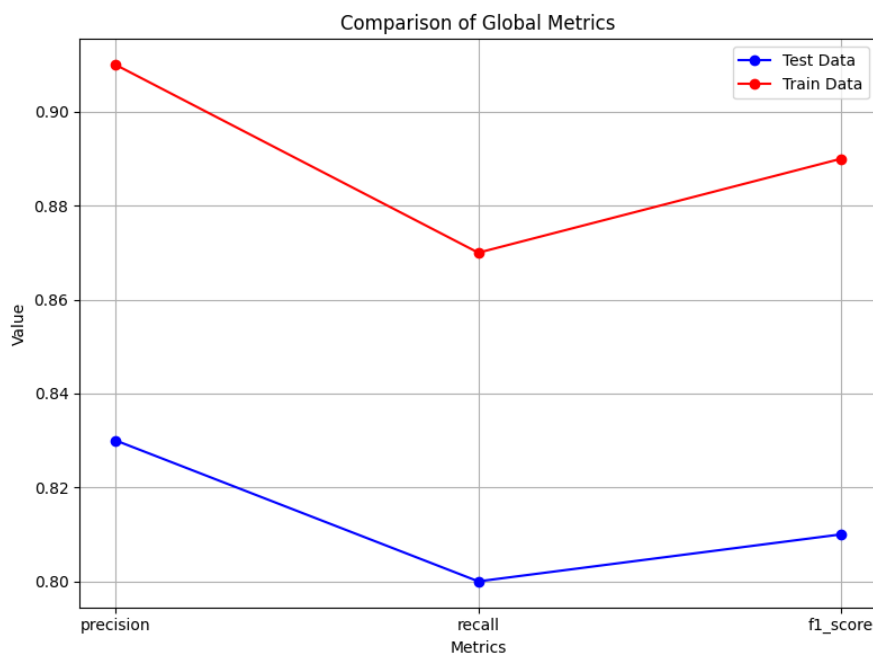


FIGURE 5 – Comparaison globale entre le set d'entraînement et de test

Sur la figure 5, les résultats mettent en évidence une priorisation de la précision par rapport au rappel, ce qui se traduit par une réduction significative des faux positifs au détriment de quelques faux négatifs. Cette orientation suggère une approche prudente du modèle dans ses prédictions, privilégiant la certitude des détections plutôt que la sensibilité à tous les objets.

4.4.2 Validation et limites du modèle

Ensuite, une analyse qualitative des résultats a été réalisée en examinant visuellement les détections effectuées par le modèle sur un ensemble de données de validation distinct (données complètement inconnues du modèle). Cette analyse qualitative a permis d'identifier les forces et les limites du modèle, ainsi que les types d'erreurs qu'il peut rencontrer dans des scénarios réels. Le nouveau set de données a été généré de façon à ce que certaines images aient du bruit de façon aléatoire (flou gaussien), et subissent des rotations aléatoires afin de perturber le modèle et de le tester dans des conditions non-optimales. On utilise ici comme métrique le F1-score [Pedregosa et al. (2011) Pedregosa, Varoquaux, Gramfort, Michel, Thirion, Grisel, Blondel, and Prettenhofer], qui est une métrique essentielle pour évaluer la performance des modèles de classification. Il combine la précision et le rappel en une seule valeur, offrant ainsi une vue globale de la capacité du modèle à effectuer des prédictions précises. Une interprétation simple du F1-score est que pour chaque prédiction positive correcte, le modèle commet un certain nombre d'erreurs, équilibrant ainsi la qualité des prédictions avec les erreurs associées.

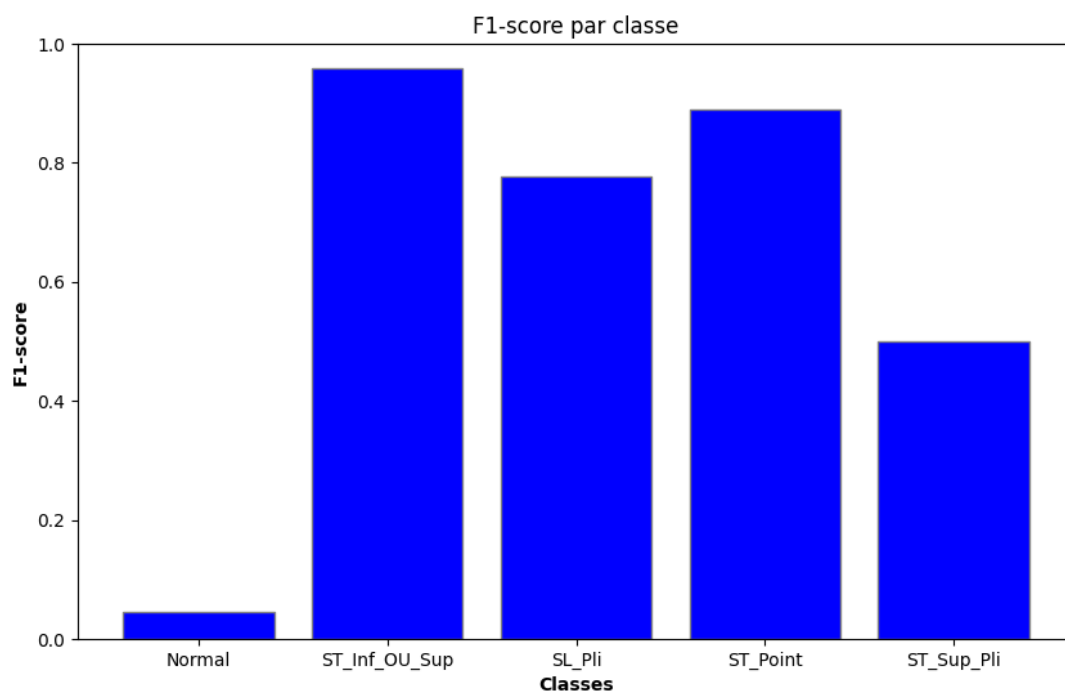


FIGURE 6 – F1-score par classe sur un nouveau set de données

Sur la figure 6 on observe plusieurs choses, d'abord les perturbations rendent la détection de la classe "Normal" extrêmement mauvaise, on obtient un F1-score de 0.05 environ qui se traduit par 1 vrai positif pour 40 erreurs. En regardant dans le détail, on se rend compte que le modèle fait beaucoup de faux négatif sur la classe "Normal" sur ce set non-optimal. Pour le reste, le modèle obtient un score assez satisfaisant malgré les conditions de détections défavorable. On peut conclure que ce modèle est assez sensible à la qualité des images qu'il prend en entrée, et qu'une bonne piste d'optimisation serait d'ajouter des images perturbées par du bruit lors de l'entraînement, permettant de rendre le modèle plus robuste.

4.5 L'interface utilisateur

L'interface qui a été réalisée permet à un utilisateur d'ouvrir une image ou un dossier d'images, et de lancer une détection de défauts dessus afin de visualiser ceux-ci avec le pourcentage de confiance du modèle sur sa prédiction. Le but était donc de rendre l'interface facile d'utilisation, claire et intuitive pour quelqu'un qui n'aurait aucune connaissance en apprentissage profond ou en informatique. L'interface fournit quelques outils pour travailler sur l'image (essentiellement zoom et dé-zoom sur l'image courante).

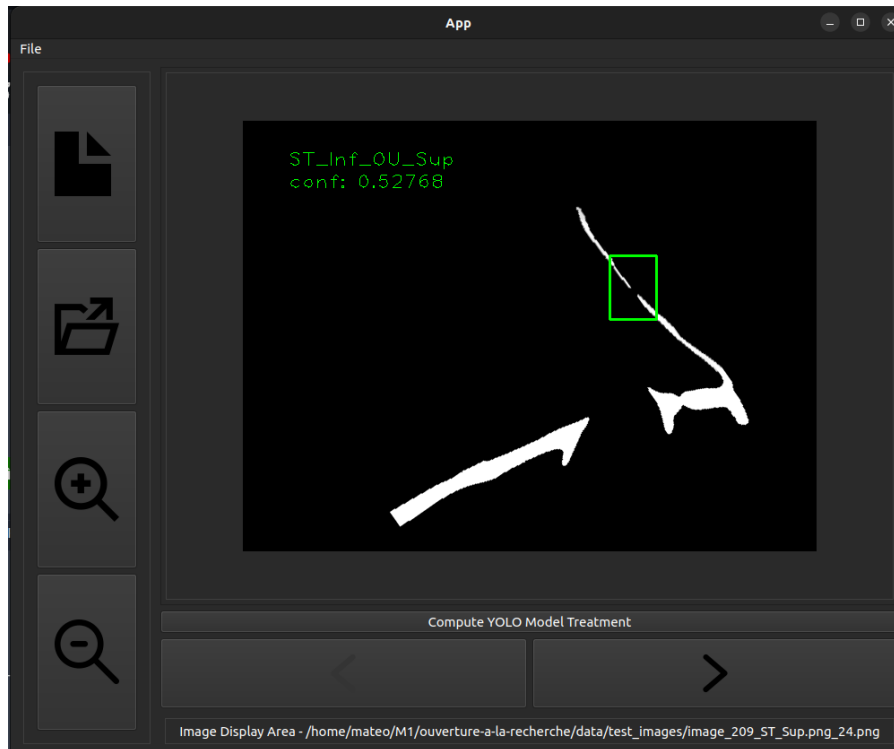


FIGURE 7 – Exemple de résultat de détection dans l'application.

Sur la figure 7, on a la vue globale de l'application. L'application est simple et le nombre d'action limité pour aller à l'essentiel. La délimitation de la zone de détection est claire et visible, ainsi que les informations telles que la classe détectée et la confiance du modèle.

5 Conclusion

À travers ce projet, plusieurs étapes ont été franchies, de la compréhension des modèles d'apprentissage profond à l'implémentation d'une interface utilisateur conviviale.

Nous avons appris que l'application de modèles de détection d'objets tels que YOLO peut être efficace pour repérer les défauts dans les images thermiques, mais nécessite un ensemble de données de haute qualité et une optimisation minutieuse des hyperparamètres pour obtenir des résultats fiables. L'importance de la labellisation précise des données et de l'augmentation des données pour améliorer la généralisation du modèle a également été soulignée.

L'analyse des résultats a permis d'identifier les forces et les limites du modèle développé. Bien qu'il ait montré une bonne précision pour détecter certains types de défauts, il reste sensible à la qualité des images en entrée et peut rencontrer des difficultés dans des conditions non-optimales. Cela souligne la nécessité continue d'améliorer la robustesse du modèle pour une utilisation pratique dans des environnements industriels variés.

Enfin, l'élaboration d'une interface utilisateur conviviale a été un aspect important du projet, permettant de rendre la technologie accessible à un large éventail d'utilisateurs. Cette interface offre une interaction intuitive avec le système de détection de défauts, facilitant ainsi son utilisation dans des scénarios réels.

Pour l'avenir, des pistes d'amélioration incluent l'exploration de techniques supplémentaires pour améliorer la robustesse du modèle, telles que l'ajout de données perturbées lors de l'entraînement et de l'exploration de modèles plus avancés. De plus, l'extension de l'interface utilisateur pour inclure des fonctionnalités supplémentaires, telles que la gestion des rapports d'inspection et la collaboration en temps réel, pourrait rendre le

système encore plus polyvalent et utile dans des environnements industriels. Enfin, la collaboration avec des experts du domaine pour affiner les critères de détection et de classification des défauts pourrait permettre d'obtenir des résultats encore plus précis et fiables.

Références

- [Luo et al.(2019)Luo, Gao, Woo, and Yang] Qin Luo, Bin Gao, W.L. Woo, and Yang Yang. Temporal and spatial deep learning network for infrared thermal defect detection. *NDT and E International*, 108 :102164, 2019. ISSN 0963-8695. doi : <https://doi.org/10.1016/j.ndteint.2019.102164>. URL <https://www.sciencedirect.com/science/article/pii/S0963869519301355>.
- [Pedregosa et al.(2011)Pedregosa, Varoquaux, Gramfort, Michel, Thirion, Grisel, Blondel, and Prettenhofer] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, and P... Prettenhofer. Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.
- [Souza et al.(2023)Souza, Stefenon, Singh, and Freire] Bruno José Souza, Stefano Frizzo Stefenon, Gurmail Singh, and Roberto Zanetti Freire. Hybrid-yolo for classification of insulators defects in transmission lines based on uav. *International Journal of Electrical Power and Energy Systems*, 148 :108982, 2023. ISSN 0142-0615. doi : <https://doi.org/10.1016/j.ijepes.2023.108982>. URL <https://www.sciencedirect.com/science/article/pii/S014206152300039X>.
- [Syberfeldt and Vuoluterä(2020)] Anna Syberfeldt and Fredrik Vuoluterä. Image processing based on deep neural networks for detecting quality problems in paper bag production. *Procedia CIRP*, 93 :1224–1229, 2020. ISSN 2212-8271. doi : <https://doi.org/10.1016/j.procir.2020.04.158>. URL <https://www.sciencedirect.com/science/article/pii/S2212827120310374>. 53rd CIRP Conference on Manufacturing Systems 2020.
- [Wang et al.(2021)Wang, Bochkovskiy, and Liao] Chien-Yao Wang, Alexey Bochkovskiy, and Hong-Yuan Mark Liao. Scaled-YOLOv4 : Scaling cross stage partial network. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 13029–13038, June 2021.

6 Annexes

Vous trouverez en annexe à ce document l'état de l'art complet qui a été réalisée pour ce projet.



État de l'art

Projet d'ouverture à la recherche - Mif11

Détection et classification automatique des défauts dans une image thermique en se basant sur les méthodes d'apprentissage profond

Matéo MUNOZ

Encadrant du projet : Hamid LADJAL

Novembre 2023 - Février 2024

Année Universitaire 2023 - 2024

Table des matières

1	Introduction	2
2	Recherches sur l'utilisation de modèles deep learning pour la détection de défauts sur une image	3
2.1	Thermographie optique pulsée dans le contrôle non destructif des matériaux composites	3
2.2	Utilisation de Hybrid-YOLO pour la classification des défauts d'isolateurs dans les lignes de transmission	3
2.3	Deep Learning pour la detection de problèmes de qualité dans la production de sacs en papier	4
3	Analyse des différents modèles de deep learning cité	5
4	Bilan	7
	Bibliographie	8

1 - Introduction

L'avancée rapide de l'intelligence artificielle (IA) et des méthodes d'apprentissage profond a considérablement transformé la manière dont nous abordons des problèmes complexes, notamment dans le domaine de l'analyse d'images. Ce chapitre d'introduction vise à situer le contexte de notre étude qui se concentre sur l'application des méthodes d'apprentissage profond pour la détection et la classification automatiques des défauts dans les images thermiques.

Les images thermiques, capturées à l'aide de caméras infrarouges, offrent une perspective unique en révélant les variations de température d'un objet ou d'une scène. Dans divers domaines tels que le contrôle non destructif des matériaux, la surveillance industrielle et l'inspection électrique, la détection précise des défauts dans ces images revêt une importance cruciale.

Notre projet s'inscrit dans le cadre de l'ouverture à la recherche du Département informatique de l'Université Claude Bernard Lyon 1 pour l'année universitaire 2023-2024. Nous explorons spécifiquement comment les méthodes d'apprentissage profond peuvent être exploitées pour améliorer la détection automatisée de défauts dans les images thermiques.

L'objectif principal de cette étude est de faire le point sur les différentes approches et méthodes utilisées dans le domaine de la détection de défauts dans des images thermiques. Nous examinons les performances de divers modèles d'apprentissage profond, leur capacité à traiter des ensembles de données limités, leur généralisation sur des ensembles variés, et leur efficacité dans des conditions environnementales variables.

Pour ce faire, nous analysons en détail trois articles de recherche récents qui explorent l'utilisation de modèles d'apprentissage profond pour la détection de défauts dans des domaines spécifiques tels que le contrôle non destructif des composites, l'inspection électrique assistée par drone, et la détection des problèmes de qualité dans la production manufacturière.

Chaque article offre des perspectives uniques et des résultats significatifs, et notre analyse vise à fournir des informations approfondies sur la pertinence et les performances de ces modèles dans le contexte de la détection de défauts thermiques.

2 - Recherches sur l'utilisation de modèles deep learning pour la détection de défauts sur une image

2.1 Thermographie optique pulsée dans le contrôle non destructif des matériaux composites

Le premier article se concentre sur l'application de la thermographie pulsée optique (OPT) pour le contrôle non destructif des composites renforcés de fibres de carbone (CFRP) utilisés dans des domaines tels que l'aérospatiale et les éoliennes. Différentes méthodes de contrôle non destructif, telles que les tests par pénétrant et la thermographie infrarouge, sont explorées, avec un accent particulier sur l'OPT en raison de ses avantages. Cependant, l'OPT présente des défis, tels que le flou des bords et la faible résolution des images thermiques.

Pour résoudre ces problèmes, l'article examine divers algorithmes d'extraction de caractéristiques, notamment l'analyse en composantes principales (PCA) et la reconstruction du signal thermographique (TSR). En outre, il explore l'utilisation de **réseaux de neurones à convolution (CNN)**, tels que **VGG**, **Segnet** et **DeepLab**, pour la segmentation des défauts dans les images thermiques infrarouges.

Une stratégie de "cross learning" est introduite pour minimiser l'illumination inégale et améliorer le taux de détection des défauts. Les résultats montrent que l'approche VGG-Unet offre de meilleures performances, combinant les avantages de la segmentation de petits ensembles d'échantillons de Unet et des poids pré-entraînés de VGG.

L'expérimentation est réalisée sur une plateforme OPT avec neuf échantillons différents, et l'article discute des impacts de l'amélioration des données et des différentes méthodes de prétraitement sur la segmentation des défauts. En conclusion, l'utilisation de réseaux de neurones pour la segmentation d'images thermiques infrarouges semble prometteuse dans le domaine du contrôle non destructif des composites, avec la stratégie de "cross learning" offrant des améliorations significatives. Des perspectives futures pourraient explorer davantage cette approche.

2.2 Utilisation de Hybrid-YOLO pour la classification des défauts d'isolateurs dans les lignes de transmission

Ce second article présente l'application d'une version hybride du modèle **You Only Look Once (YOLO)**, nommée Hybrid-YOLO, pour la classification des défauts d'isolateurs dans les lignes de transmission, avec une attention particulière sur son efficacité. L'utilisation de ce modèle, combinée à des images réelles de composants défectueux enregistrées par des drones, vise à améliorer la rapidité et la précision de l'identification des défauts électriques.

Les résultats démontrent que le modèle Hybrid-YOLO surpasse plusieurs versions de YOLO en termes de détection d'objets, obtenant une précision moyenne (mAP) de 0.99262. L'article souligne également sa supériorité par rapport à d'autres architectures établies, telles que VGG-11, VGG-13, ResNet-34,

YOLOv5, et d'autres, en particulier pour la tâche de classification multiclassées, avec un F1-score de 0.96216.

Une caractéristique notable du modèle Hybrid-YOLO est sa capacité à fournir des résultats exceptionnels avec un petit ensemble de données. Malgré le défi que représente l'apprentissage sur un ensemble limité, le modèle parvient à surpasser ses prédécesseurs en termes de performances, démontrant ainsi son efficacité même dans des conditions où l'information disponible est restreinte.

L'article conclut que le modèle Hybrid-YOLO, en combinant la rapidité de YOLO avec le classificateur ResNet-18, offre une approche efficace et prometteuse pour la détection des défauts d'isolateurs dans les lignes de transmission. Cette efficacité s'étend à la fois à la détection d'objets et à la classification multiclassées, soulignant le potentiel de cette approche dans le domaine de l'inspection électrique assistée par drone.

2.3 Deep Learning pour la detection de problèmes de qualité dans la production de sacs en papier

Cet article offre une perspective sur les défis auxquels sont confrontées les entreprises manufacturières en raison de l'évolution rapide des communications et de la demande croissante de personnalisation des produits. Il met en lumière la nécessité critique de modéliser et d'analyser les produits, non seulement en considérant des familles de produits existantes, mais aussi en explorant la possibilité de définir de nouvelles familles de produits pour répondre à la variété croissante des marchés.

Une partie significative de l'article se concentre ensuite sur l'application spécifique du deep learning dans le contexte de la détection automatique des problèmes de qualité dans la production de sacs en papier. L'utilisation d'un réseau neuronal profond, en particulier le modèle **Faster R-CNN**, est mise en avant. Ce modèle, une variante de CNN (réseau de neurones convolutif), est implémenté à l'aide de TensorFlow, une bibliothèque de pointe en matière d'apprentissage automatique.

Les résultats de cette approche soulignent l'efficacité du modèle Faster R-CNN, atteignant une précision de 94,5%. Cette performance s'avère être une alternative prometteuse à l'inspection manuelle, traditionnellement coûteuse et sujette à des erreurs humaines. L'article souligne que la détection et l'élimination des produits de qualité médiocre demeurent des aspects cruciaux pour garantir des produits de haute qualité dans le secteur manufacturier.

Par ailleurs, l'article met en évidence les limitations des systèmes basés sur des caméras automatiques, souvent freinés par des problèmes de performance et de flexibilité, notamment en raison de variations environnementales telles que des changements d'éclairage. Il souligne ainsi comment le deep learning, en particulier avec des modèles comme Faster R-CNN, pourrait surmonter ces obstacles et offrir une solution plus robuste et automatisée pour les inspections de qualité.

3 - Analyse des différents modèles de deep learning cité

Précision de la détection des défauts :

1. **Hybrid-YOLO (Article 2)** : Obtient une précision moyenne (mAP) de 0.99262, dépassant les autres modèles dans la détection d'objets.
2. **VGG-Unet avec stratégie de "cross learning" (Article 1)** : Offre de bonnes performances en combinant les avantages de la segmentation de petits ensembles et des poids pré-entraînés de VGG.
3. **Faster R-CNN (Article 3)** : Bien que très précis (94,5%), se classe troisième en raison de performances légèrement inférieures aux deux autres. Notez que ce critère est peu déterminant car l'écart de performances est assez minime dans notre domaine d'application, et surtout que les modèles cités ne sont pas testés sur des applications vraiment similaires. L'environnement et le domaine n'étant jamais le même.

Capacité à traiter des ensembles de données limités :

1. **Hybrid-YOLO (Article 2)** : Excellente performance avec un petit ensemble de données, surpassant d'autres architectures.
2. **Faster R-CNN (Article 3)** : Bien que performant, la nécessité de vérifier la généralisation sur des ensembles plus vastes le place en deuxième.
3. **VGG-Unet avec stratégie de "cross learning" (Article 1)** : Bien que performant, la généralisation pourrait nécessiter davantage d'exploration.

Généralisation sur des ensembles de données variés :

1. **Hybrid-YOLO (Article 2)** : Se distingue par sa capacité à généraliser sur des ensembles de données variés.
2. **VGG-Unet avec stratégie de "cross learning" (Article 1)** : Performant, mais la généralisation nécessite d'être explorée plus en détail.
3. **Faster R-CNN (Article 3)** : En dernière position en raison de préoccupations potentielles liées à la généralisation.

Efficacité dans des conditions environnementales variables :

1. **VGG-Unet avec stratégie de "cross learning" (Article 1)** : Sa capacité à minimiser l'illumination inégale et à améliorer la détection des défauts dans des conditions variables le place en première position.
2. **Hybrid-YOLO (Article 2)** : Performant mais classé deuxième en raison de l'accent particulier du modèle VGG-Unet sur les conditions variables.
3. **Faster R-CNN (Article 3)** : Classé en troisième position, nécessitant une évaluation plus approfondie de sa robustesse dans des conditions variables.

Prise en main et Adaptabilité du modèle :

1. **VGG-Unet avec stratégie de "cross learning" (Article 1)** : La combinaison d'Unet et de poids pré-entraînés de VGG offre une facilité de prise en main et une adaptabilité.
2. **Faster R-CNN (Article 3)** : La rapidité du modèle le rend facile à utiliser, mais la complexité peut affecter la prise en main.
3. **Hybrid-YOLO (Article 2)** : Bien que performant, la combinaison de YOLO et ResNet-18 pourrait nécessiter une courbe d'apprentissage plus prononcée.

4 - Bilan

Le modèle YOLO (You Only Look Once) est souvent choisi dans des scénarios de détection d'objets en raison de ses caractéristiques distinctes et de ses avantages particuliers, même si le modèle mentionné précédemment est Hybrid-YOLO. Voici quelques arguments spécifiques en faveur de l'utilisation de YOLO :

Efficacité et Vitesse : YOLO est réputé pour sa rapidité d'exécution. En traitant l'image entière en un seul passage, YOLO évite la nécessité de plusieurs traitements pour détecter des objets, ce qui le rend plus rapide par rapport à des approches basées sur la détection d'ancres comme dans Hybrid-YOLO.

Simplicité de l'architecture : YOLO propose une architecture simple et élégante. La simplicité du modèle le rend plus facile à comprendre, à mettre en œuvre et à ajuster, ce qui peut être un avantage pour les projets nécessitant une mise en œuvre rapide et une maintenance simplifiée.

Robustesse avec des ensembles de données variés : YOLO a montré une bonne robustesse et une capacité de généralisation sur des ensembles de données variés. Cela peut être essentiel dans des applications réelles où les conditions et les caractéristiques des données peuvent varier.

Convivialité pour la production : YOLO est souvent préféré dans des applications de production en raison de sa rapidité et de sa simplicité. Sa capacité à fournir des résultats en temps réel en fait un choix idéal pour des scénarios tels que la surveillance vidéo **et la détection d'objets en temps réel**.

Disponibilité de ressources : En raison de sa popularité, YOLO bénéficie d'une vaste communauté de développeurs, de tutoriels et de ressources en ligne. Cela facilite l'apprentissage lié à son utilisation.

Bien que Hybrid-YOLO puisse offrir des améliorations spécifiques, le choix d'opter pour YOLO est motivé par sa simplicité, sa rapidité et sa robustesse dans une variété de contextes d'application. Enfin, beaucoup de ressources sont disponibles pour apprendre à utiliser YOLO tout en obtenant des résultats satisfaisants. Ce point est déterminant dans le choix du modèle YOLO en raison du temps disponible au développement.

Bibliographie

- [1] Qin LUO et al. “Temporal and spatial deep learning network for infrared thermal defect detection”. In : *NDT and E International* 108 (2019), p. 102164. ISSN : 0963-8695. DOI : <https://doi.org/10.1016/j.ndteint.2019.102164>.
- [2] Bruno José SOUZA et al. “Hybrid-YOLO for classification of insulators defects in transmission lines based on UAV”. In : *International Journal of Electrical Power and Energy Systems* 148 (2023), p. 108982. ISSN : 0142-0615. DOI : <https://doi.org/10.1016/j.ijepes.2023.108982>.
- [3] Anna SYBERFELDT et Fredrik VUOLUTERÄ. “Image Processing based on Deep Neural Networks for Detecting Quality Problems in Paper Bag Production”. In : *Procedia CIRP* 93 (2020). 53rd CIRP Conference on Manufacturing Systems 2020, p. 1224-1229. ISSN : 2212-8271. DOI : <https://doi.org/10.1016/j.procir.2020.04.158>.